FNC 第 2 章：线性方程组

2. Linear systems of equations • 120 分钟主线 + 60 分钟练习

依据 Tobin A. Driscoll 与 Richard J. Braun 的 *Fundamentals of Numerical Computation*，按用户指定的 Julia 版第 2 章整理。范围完整覆盖 2.1–2.10；2.10 是延伸阅读。原文标题保留，解释、补充例子和学习安排为编者撰写。访问日期：2026-10-26。习题另见 `fnc-ch2-exercises.pdf`，共 61 道大题。

先定目标与学习顺序

三小时的合理目标：能建模、能选求解方法、能解释结果是否可信。 要同时熟练完成全部证明和 61 道习题，三小时不够。这里不删章节；用主线理解全部概念，用少量练习检验应用，较长证明留作后续巩固。

假设你已接触矩阵乘法、线性方程组和基本循环。开始前检查：能否判断 $(3\times 2)(2\times 4)$ 的结果尺寸？能否从 $2x_2=6$ 求出 x_2，再代入 $x_1+x_2=4$？若不能，先补矩阵基础；下面的时间估计不再适用。Julia 不熟可使用本讲义的语法表，不必先读完整语言教程。

时间	阅读与动手内容	完成标准
0–10 分钟	前置检查、浏览全章关系	说清输入是 A,b，输出是 x
10–25 分钟	2.1，配合自检 1	能把插值写成 $Vc=y$
25–40 分钟	2.2	分清矩阵乘法、逐元素操作和行列变换
40–60 分钟	2.3–2.4，配合自检 2	手算三角求解，解释 LU 的两次代入
60–75 分钟	2.5–2.6	说清成本和换行理由，正确重排 b
75–95 分钟	2.7–2.8	算范数，联合残差与条件数判断可信度
95–105 分钟	2.9–2.10	区分一般、三对角、对称、SPD 矩阵
105–120 分钟	合上正文做其余自检，再查答案	至少完成 6/7，并纠正错误理由

若有第三小时，依次做习题册：2.1.1(c)（10 分钟）、2.6.1(a)（15 分钟）、2.7.6(a,b)（10 分钟）、2.8.5（15 分钟）、2.9.2（10 分钟）。这是编者按概念依赖选择的练习，不代表考试频率。如果环境未就绪，将编程题先写成算法步骤，实际运行另计时间。

全章关系只有一条主线：**实际问题 → $Ax=b$ → 分解与三角代入 → 用结构节省计算 → 用残差和条件数检查结果。**

2.1. Polynomial interpolation | 多项式插值

来源：2.1。对应原文 Definition 2.1.1、Vandermonde matrix 与 Demo 2.1.3。

从数据到线性方程组

给定 n 个点 (t_i,y_i)，**所有 t_i 互异**，求次数严格小于 n 的多项式，使 $p(t_i)=y_i$。这个多项式存在且唯一。“小于 n”是至多 $n-1$ 次，实际次数可以更低；n 个点不一定需要恰好 $n-1$ 次。

用升幂系数写成

$$p(t) = c_1 + c_2 t + \cdots + c_n t^{n-1}, \qquad V_{ij} = t_i^{j-1}.$$

代入每个数据点，得到原文式 (2.1.2)：

$$Vc = y, \qquad V = \begin{bmatrix} 1 & t_1 & \cdots & t_1^{n-1} \\ \vdots & \vdots & & \vdots \\ 1 & t_n & \cdots & t_n^{n-1} \end{bmatrix}.$$

V 是 Vandermonde 矩阵。直观上：未知量是系数，数据点各提供一个线性约束；**多项式对 t 非线性，不妨碍它对系数线性。**唯一性的理由：两份解相减后至多 $n-1$ 次，却有 n 个不同零点，只能是零多项式。

补充例子。 对 $(0,1),(1,2),(2,5)$，有

$$\begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \\ c_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 5 \end{bmatrix}.$$

解得 $c = (1,0,1)^T$，所以 $p(t) = 1 + t^2$，$p(1.5) = 3.25$。检查插值节点处是否复现数据，再判断中间预测是否有实际依据。

实际应用与容易误判之处

- 年份等横坐标宜平移、缩放，例如 $t = (\text{year} - 2000)/10$，避免直接计算巨大高次幂；求值时必须用同一变量变换。变换有助于尺度，但不保证消除病态。
- 插值在数据范围内估计；超出范围属于外推。**节点拟合精确，不代表模型预测准确。** 增加节点并提高次数也可能产生振荡，详见第 9 章。
- 观测值有噪声时，强行穿过所有点未必合适；最小二乘属于第 3 章，本章不把它当成插值。
- 补充：习题 2.1.2 的 Hermite 插值还约束导数。将 $p(t)$ 或 $p'(t)$ 代入给定位置，依旧得到关于系数的线性方程。

```
using LinearAlgebra
t = [0.0, 1.0, 2.0]
y = [1.0, 2.0, 5.0]
V = [t[i]^j for i in eachindex(t), j in 0:2]
c = V \ y                    # 升幂顺序，不是求逆
p(s) = sum(c[j+1]*s^j for j in 0:2)
@show p(1.5) norm(y - V*c)
```

2.2. Computing with matrices | 矩阵计算

来源：2.2。对应 Notation、Block matrix expressions、Vectors and matrices in Julia、Row and column operations。

记号、尺寸与乘法

本章向量默认作列向量。A_{ij} 是矩阵元素，a_j 是第 j 列，e_j 是单位矩阵的第 j 列。A^T 为转置；A^* 为共轭转置。实矩阵两者相同，复矩阵要区分。对称指 $A^T = A$。

若 A 为 $m \times n$、B 为 $n \times p$，则 AB 为 $m \times p$。内部尺寸必须一致。

$$(AB)_{ij} = \sum_{k=1}^{n} A_{ik} B_{kj}, \qquad Ax = \sum_{j=1}^{n} x_j a_j.$$

前一个公式是“行与列做内积”，后一个是“按 x_j 加权组合各列”。矩阵乘法通常不交换；交换顺序可能连尺寸都不兼容。

分块矩阵按同样规则相乘，前提是**每项块乘法都兼容，且相加的块尺寸相同。**例如

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} = \begin{bmatrix} Au + Bv \\ Cu + Dv \end{bmatrix}.$$

转置会同时交换块位置并转置块本身。需记住

$$(AB)^T = B^T A^T, \qquad (AB)^{-1} = B^{-1} A^{-1}$$

其中逆公式要求 A, B 均为可逆方阵。证明逆公式时检查乘回去得到 I，不要擅自交换 A 和 B。

行、列操作是乘法

$$Ae_j = a_j, \qquad e_i^T A = \text{第 } i \text{ 行}, \qquad e_i^T A e_j = A_{ij}.$$

左乘改变行，右乘改变列。 用单位矩阵的行或列选取、交换、加权，可统一表达许多操作。例如 $A(e_1 + 2e_3)$ 是“第 1 列加两倍第 3 列”；它只有一列。若要原位替换第 1 列，其余列不变，右乘矩阵也必须保留其余单位列。

本章够用的 Julia 语法

操作	Julia 写法	核心区别
列向量 / 单行矩阵	`[1,2,3]` / `[1 2 3]`	前者是一维数组，后者是 1×3 矩阵
建矩阵 / 块拼接	`[1 2; 3 4]`；`[A B; C D]`	空格横拼，分号竖拼
大小	`size(A)`、`size(A,1)`、`length(A)`	行列尺寸 / 行数 / 全部元素个数
切片	`A[:,j]`、`A[i,:]`、`A[1:2,end]`	切出的单列、单行通常都成为一维向量
范围	`1:2:9`；`range(0,1,length=5)`	起点:步长:终点；或指定点数
转置 / 共轭转置	`transpose(A)` / `A'`	实数相同，复数不同
矩阵乘法 / 逐项乘法	`A*B` / `A.*B`	一个是线性代数，一个是广播
矩阵幂 / 逐项幂	`A^2` / `A.^2`	$A^2 = AA$；`.^2` 对每个元素平方
逐项函数	`sin.(x)`、`@. sin(x+1)`	点表示广播，可扩展标量
特殊元素	`zeros(n,n)`、`ones(n)`、`diagm(v)`	零阵、全一向量、对角矩阵
三角 / 对角线	`tril(A)`、`triu(A)`、`diag(A,k)`	下三角、上三角、第 k 条对角线
复制 / 浮点转换	`copy(A)`、`float.(A)`	`B=A` 共享数据；整数数组不能随意存小数

Julia 从 1 开始索引。`end` 指当前维度最后一个位置。`!` 是函数可能修改输入或状态的命名惯例；`+=` 是更新赋值。广播支持可兼容的形状，不能据此把维度不匹配的矩阵乘法变成合法。

2.3. Linear systems | 线性方程组与三角求解

来源：2.3。对应 Don't use the inverse、Triangular systems、Implementation；Function 2.3.4 `forwardsub`、Function 2.3.5 `backsub`。

数学表达式与实际算法

对 $n \times n$ 方阵 A，$Ax = b$ 在 A 可逆时有唯一解 $x = A^{-1}b$。若 A 奇异，可能无解，也可能有无穷多解，取决于 b。实际计算用 `A\b`，不要先 `inv(A)*b`；显式求逆增加工作量，也没有提供求解所需的额外价值。

`rank`、`det(A)==0` 或一次运行是否报错，都不是可靠的浮点“接近奇异”诊断。后面用条件数衡量这个连续变化的困难程度。

前代与回代

下三角 $Lx = b$ 从第一行往下，叫前代；上三角 $Ux = b$ 从最后一行往上，叫回代：

$$x_i = \frac{b_i - \sum_{j=1}^{i-1} L_{ij}x_j}{L_{ii}} \quad (i = 1, \ldots, n),$$

$$x_i = \frac{b_i - \sum_{j=i+1}^{n} U_{ij}x_j}{U_{ii}} \quad (i = n, \ldots, 1).$$

空和视为零。**每个对角元素都必须非零**；三角矩阵可逆当且仅当对角线上没有零。小主元即使非零，也可能放大数值误差。

补充例子：

$$\begin{bmatrix} 2 & 0 & 0 \\ 3 & 1 & 0 \\ -1 & 2 & 4 \end{bmatrix} x = \begin{bmatrix} 2 \\ 5 \\ 15 \end{bmatrix} \Rightarrow x_1 = 1,\ x_2 = 2,\ x_3 = 3.$$

实现时外层按求解顺序循环，内层累加已经求出的分量。用浮点数组存结果，注意 $n = 1$ 和空循环；不必为公式简短而写出会在空生成器上失败的求和。

用残差检验，但暂时别下准确性结论

对计算解 $\hat{x}$，残差 $r = b - A\hat{x}$ 可直接算出，真误差 $x - \hat{x}$ 通常算不出。浮点计算下不应要求 `A*x == b` 严格成立，应看相对尺度。**三角方程也可能病态**：例如先存下 $\alpha - \beta$，再加回 β，当 $|\beta| \gg |\alpha|$，有效数字可能早已丢失。

2.4. LU factorization | LU 分解

来源：2.4。对应 Outer products、Triangular product、Triangular factorization、Gaussian elimination and linear systems；Function 2.4.6 `lufact`。

外积视角为什么有用

若 $u \in \mathbb{R}^m, v \in \mathbb{R}^n$，则外积 uv^T 为 $m \times n$ 矩阵，第 (i, j) 项为 $u_i v_j$；内积 $u^T v$ 在向量等长时是标量。外积一般不交换。

将 A 的列记为 a_k、B 的行记为 b_k^T，矩阵乘法还能写成

$$AB = \sum_{k=1}^{n} a_k b_k^T.$$

对下三角 L 和上三角 U，LU 的第一行、第一列只有第一项外积有贡献。这让我们能逐个取出外积、更新剩余矩阵。

分解与消元是一件事的两种记录方式

目标 $A = LU$，其中 L 为**单位下三角**，U 为上三角。令 L 的对角线全为 1，是为固定缩放自由度。

设当前剩余矩阵为 S。第 k 步：

$$U_{k,k:n} = S_{k,k:n}, \qquad L_{k+1:n,k} = S_{k+1:n,k}/U_{kk},$$
$$S_{k+1:n,k+1:n} \leftarrow S_{k+1:n,k+1:n} - L_{k+1:n,k}U_{k,k+1:n}.$$

U_{kk} 是主元，L_{ik} 存第 i 行消元时用的倍数。不换行高斯消元能顺利进行时，记录这些倍数便得到 LU。

补充例子：

$$A = \begin{bmatrix} 2 & 1 \\ 4 & 3 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}.$$

若 $b = (3, 7)^T$，先 $Lz = b$ 得 $z = (3, 1)^T$，再 $Ux = z$ 得 $x = (1, 1)^T$。**顺序永远是先 L 后 U**，来自 $L(Ux) = b$。

条件、复用与副产品

- 可逆矩阵也可能遇到零主元，普通 LU 不保证存在。补充判据：可逆方阵在不换行条件下能完成这种单位下三角 LU，当且仅当各阶顺序主子式均非零。实际工作不逐个算行列式，而使用换行。
- 分解只依赖 A，不依赖 b。同一 A 对多个右端项，分解一次后重复前代、回代；也可将右端项排成 B，一次解 $AX = B$。
- 不换行时 $\det A = \prod_i U_{ii}$，因为 $\det L = 1$。换行版本还必须计入置换的正负号。
- 教材 `lufact` 为教学代码，不是一般矩阵的可靠默认求解器。更新前应复制原数组，并转成能存放商的浮点类型。

2.5. Efficiency of matrix computations | 计算效率

来源：2.5。对应 Asymptotic analysis、Flop counting、Solution of linear systems。

两种渐近记号别混用

对最终为正的 f, g，$f = O(g)$ 表示 f/g 在极限中有上界；$f \sim g$ 表示 $f/g \to 1$。前者只约束增长阶，后者连首项常数也一致。例：$3n^2 + n = O(n^2)$，但它渐近于 $3n^2$，不渐近于 n^2。在 $h \to 0^+$ 时也要重新算比值，不能照搬 $n \to \infty$ 的大小关系。

$$\sum_{k=1}^{n} k = \frac{n(n+1)}{2}, \qquad \sum_{k=1}^{n} k^2 = \frac{n(n+1)(2n+1)}{6}.$$

对固定非负整数 p，$\sum_{k=1}^{n} k^p \sim n^{p+1}/(p+1)$。固定地移动上下界不改变这个最高次项。

运算量怎么数

本章将一次标量加、减、乘、除、平方根各算 1 flop；赋值、索引和访存不计。这是性能模型，不是秒数预测。

常规算法	运算量	n 加倍的大致变化
两个 n 维向量内积	精确为 $2n-1$	约 2 倍
稠密矩阵乘向量	$\sim 2n^2$	约 4 倍
两个稠密方阵相乘	$\sim 2n^3$	约 8 倍
一次三角求解	$\sim n^2$	约 4 倍
优化的 LU / PLU 分解	$\sim \frac{2}{3}n^3$	约 8 倍
分解已有后的一个新右端项	$\sim 2n^2$	约 4 倍

消元第 k 步更新约 $(n-k)^2$ 个数，每项一次乘、一次减，所以总量的主项是 $2\sum_{k=1}^{n-1}(n-k)^2 \sim 2n^3/3$。只背 $O(n^3)$ 而说不出这个平方从哪里来，说明还没有理解算法。

对 m 个右端项，复用分解的总成本约为 $\frac{2}{3}n^3 + 2mn^2$；每次重新分解则约为 $m(\frac{2}{3}n^3 + 2n^2)$。教材便于阅读的全矩阵外积实现会多做已知零上的运算，不能直接拿最优首项常数解释它的运行时间。

计时与原文计数提示

若 $t \approx Cn^p$，则 $\log t \approx p\log n + \log C$；双对数图的斜率近似为 p。计时需先运行一次以完成 JIT 编译，多次重复，并排除数据生成等不相关工作。缓存、内存、线程、库实现都可能改变观测曲线。

编者核对：原文式 (2.5.3) 的精确计数不一致。 按 Function 2.3.4 的代码计数，第一项 1 flop，其余每行 $2i-1$ flop，故为 $1+\sum_{i=2}^{n}(2i-1) = n^2$。原文印出的 $1+\sum_{i=1}^{n}(2i-3)$ 不等于这个数，但“渐近为 n^2”的结论不变。习题 2.5.6 指向另一个式子 (2.5.4)，须按该式子本身计算。

2.6. Row pivoting | 换行选主元

来源：2.6。对应 Choosing a pivot、Permutations、Linear systems、Stability；Function 2.6.7 `plufact`。

为什么非零还不够

$A = \begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix}$ 可逆，却无法用左上角的零作第一主元；换两行即可。更隐蔽的问题是极小非零主元。例如

$$A = \begin{bmatrix} -\epsilon & 1 \\ 1 & -1 \end{bmatrix}, \quad L = \begin{bmatrix} 1 & 0 \\ -1/\epsilon & 1 \end{bmatrix}, \quad U = \begin{bmatrix} -\epsilon & 1 \\ 0 & 1/\epsilon - 1 \end{bmatrix}.$$

$0 < \epsilon \ll 1$ 时，原问题并不很敏感，普通 LU 却引入巨大中间量，造成不必要的数字损失。这是**算法不稳定**，不能都怪问题病态。

部分选主元的规则：在当前第 k 列的**尚未消元部分**选绝对值最大的元素，将它所在行换到第 k 行；并列时选最小行号。这样消元倍数的绝对值不超过 1。若这部分全零，精确算术下意味着矩阵奇异。

固定置换约定，避免把方向写反

本讲义将置换矩阵 P 定义为 $PA = A[p,:]$，于是

$$PA = LU, \qquad Lz = Pb, \qquad Ux = z.$$

所以不仅 A 换行，b **也必须同样换行。**置换矩阵满足 $P^{-1} = P^T$。有的资料将分解写为 $A = PLU$，使用的是相反的置换约定；判断代码时直接检查它满足哪个等式。

```
F = lu(A)                    # 含部分选主元的分解对象
@show norm(A[F.p,:] - F.L*F.U)
x = F \ b                    # 自动处理右端项置换
# 显式分步时：
z = F.L \ b[F.p]
x2 = F.U \ z
```

不要把最后两步写成 `U \ L \ b[p]`：反斜杠按左结合计算，含义会变成先求 `U\L`。写 `U \ (L \ b[p])` 才表达预期顺序。

稳定性结论的边界

精确算术下，换行 LU 可完成当且仅当 A 可逆。浮点数下，部分选主元 LU 在通常应用中可靠，但存在增长因子很大的反例，因此不能写“对所有矩阵都无条件稳定”。换行解决计算路径的问题，不能治好 A 自身的病态。

2.7. Vector and matrix norms | 向量与矩阵范数

来源：2.7。对应 Vector norms、Matrix norms；Definition 2.7.4、Theorem 2.7.5。

向量的大小与距离

范数必须非负、仅在零向量时为零、满足 $\|\alpha x\| = |\alpha|\|x\|$，并满足三角不等式 $\|x+y\| \le \|x\| + \|y\|$。

$$\|x\|_1 = \sum_i |x_i|, \qquad \|x\|_2 = \sqrt{\sum_i |x_i|^2}, \qquad \|x\|_\infty = \max_i |x_i|.$$

例如 $x = (2,-3,1,-1)^T$，三种范数分别是 $7, \sqrt{15}, 3$。非零向量除以其范数得到该范数下的单位向量；不同范数的“单位”不一样。复向量的 2 范数应写成 $\sqrt{x^*x}$。

$\|x_k - x\| \to 0$ 定义向量收敛。**固定有限维空间**内，任一范数下收敛等价于逐分量收敛，也等价于其他范数下收敛；这不表示范数数值相等。

矩阵的大小是“最多把向量放大多少”

由向量范数诱导的矩阵范数为原文式 (2.7.5)：

$$\|A\|_p = \max_{\|x\|_p=1} \|Ax\|_p = \max_{x\neq 0} \frac{\|Ax\|_p}{\|x\|_p}.$$

两种形式等价，因为任意非零向量都能归一化，而 A 是线性映射。诱导范数兼容乘法：

$$\|Ax\| \le \|A\|\|x\|, \qquad \|AB\| \le \|A\|\|B\|, \qquad \|A^k\| \le \|A\|^k \quad (k \ge 0).$$

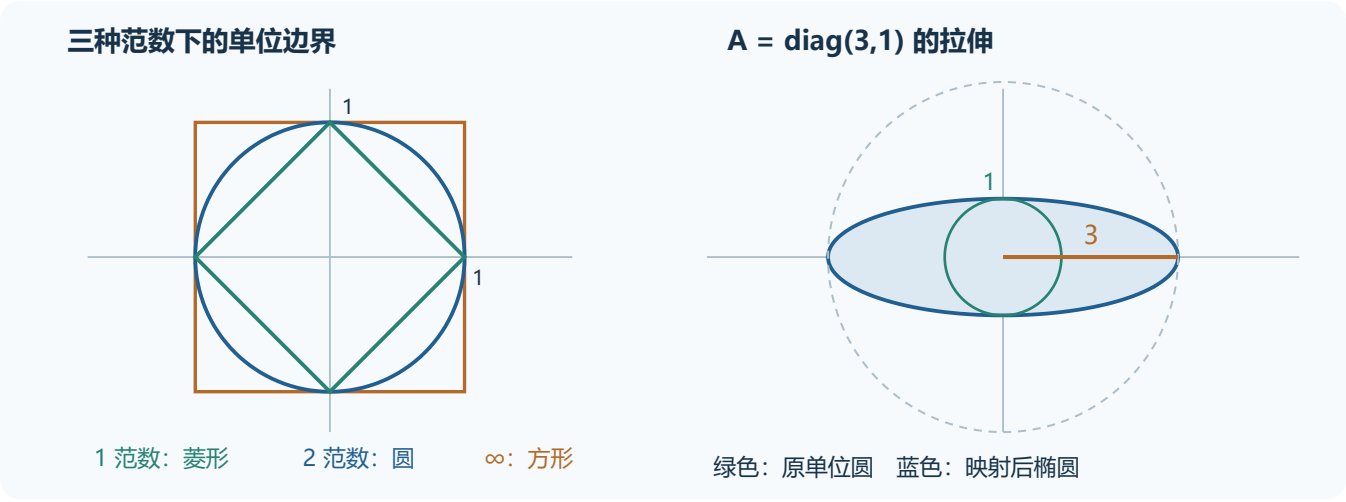
这些式子中向量范数和诱导矩阵范数必须匹配，不能随便混用下标。

范数	计算方法	Julia
$\|A\|_1$	最大的列绝对值和	`opnorm(A,1)`
$\|A\|_\infty$	最大的行绝对值和	`opnorm(A,Inf)`
$\|A\|_2$	单位 2 范数向量的最大放大倍数	`opnorm(A)`

范数	计算方法	Julia
$\|A\|_F$	$\sqrt{\sum_{i,j}\|A_{ij}\|^2}$	`norm(A)`

`norm(A)` 对矩阵默认给 Frobenius 范数，不是诱导 2 范数。 `norm(x)` 对向量默认才是向量 2 范数。1 范数沿列求和，∞ 范数沿行求和，都必须先取绝对值。

补充算例：$A=\begin{bmatrix}1 & -2\\ 3 & 4\end{bmatrix}$ 的 $\|A\|_1=6$、$\|A\|_\infty=7$、$\|A\|_F=\sqrt{30}$。诱导 2 范数不能用“元素平方求和”替代；第 7 章才详细讨论它的计算。



补充示意：三种单位圆与矩阵对单位圆的拉伸

图为编者重绘的补充示意，对应原文范数几何解释。左图三个边界分别表示范数等于 1；右图 $A=\mathrm{diag}(3,1)$ 把单位圆变成椭圆，最大放大倍数为 3，所以 $\|A\|_2=3$。

习题中出现的延伸结论

以下是同一套定义的直接推论，供做证明题时回查；完整证明可以放在首次三小时学习之后。

- $\|x\|_\infty\le\|x\|_2\le\|x\|_1$；更定量地，$\|x\|_1\le\sqrt{n}\|x\|_2$、$\|x\|_2\le\sqrt{n}\|x\|_\infty$。
- $|x^Ty|\le\|x\|_1\|y\|_\infty$，因为逐项取绝对值后可将最大 $|y_i|$ 提出。
- 任意诱导范数下 $\|I\|=1$；可逆时 $\|A^{-1}\|\ge 1/\|A\|$。对本章的 $p=1,2,\infty$，还有 $\|A\|_p\ge\max_{i,j}|A_{ij}|$。
- 对角矩阵 D 在 $p=1,2,\infty$ 下均有 $\|D\|_p=\max_i|D_{ii}|$。
- 若某诱导范数下 $\|A\|<1$，则 $I-A$ 可逆、$A^m\to 0$，并有 $(I-A)^{-1}=\sum_{k=0}^{\infty}A^k$。用有限等比和乘 $I-A$ 后取极限；不能省略收敛条件。

2.8. Conditioning of linear systems | 条件数与误差

来源：2.8。对应 Main result、Residual and backward error；Demo 2.8.3。

条件数衡量问题敏感度

对可逆方阵 A，在同一种诱导范数下定义

$$\kappa_p(A)=\|A\|_p\|A^{-1}\|_p\ge 1.$$

奇异矩阵按约定取 $\kappa=\infty$。`cond(A)` 默认给 2 范数条件数。概念上有逆不等于实际计算时应先调用 `inv`。

当只有 b 改变、A 固定时，$A\Delta x = \Delta b$，因此

$$\frac{\|\Delta x\|}{\|x\|} \le \kappa(A)\frac{\|\Delta b\|}{\|b\|}.$$

这里假设 A 可逆、$b \neq 0$，使用匹配的范数。它是**最坏情况上界**，不是每次扰动都必然放大 κ 倍；实际放大与方向有关。

当 A, b 都改变时，原文只给 A 扰动的局部结果。补充一个避免误用的有限扰动界：令 $\delta_A = \|\Delta A\|/\|A\|$、$\delta_b = \|\Delta b\|/\|b\|$，若 $\kappa(A)\delta_A < 1$，则

$$\frac{\|\Delta x\|}{\|x\|} \le \frac{\kappa(A)}{1-\kappa(A)\delta_A}(\delta_A + \delta_b).$$

原文 $\kappa(A)\delta_A$ 是小扰动下的一阶量，不能无条件当作任意大小矩阵扰动的精确上界。

残差、后向误差、前向误差要分开

$$r = b - A\hat{x}, \qquad A\hat{x} = b - r, \qquad x - \hat{x} = A^{-1}r.$$

量	回答的问题	是否通常可算
前向误差 $x - \hat{x}$	算出的解离真解多远?	否，通常不知道真解
残差 r	算出的解还差多少才满足原方程?	是
只允许改 b 的后向误差 $-r$	改多少输入可让算出的解精确成立?	是
条件数 $\kappa(A)$	输入小改变最多会使解相对改变多少?	可计算或估计

于是有本章最有用的诊断式：

$$\frac{\|x - \hat{x}\|}{\|x\|} \le \kappa(A)\frac{\|r\|}{\|b\|}.$$

小残差 + 大条件数，不能保证小误差。 只检查残差就宣布“结果很准”，是本章最需要纠正的误判。

补充一个精确算术反例：$A = \mathrm{diag}(1, 10^{-8})$，$b = (1, 10^{-8})^T$，真解 $x = (1,1)^T$。若 $\hat{x} = (1,0)^T$，相对残差约为 10^{-8}，相对解误差却约为 0.707，因为 $\kappa_2(A) = 10^8$。

补充常用整体诊断量：

$$\eta = \frac{\|b - A\hat{x}\|}{\|A\|\|\hat{x}\| + \|b\|}.$$

分母非零时，它衡量残差相对于整道问题的数据尺度有多小，也可联系允许 A, b 同时扰动的范数型后向误差。它与 $\|r\|/\|b\|$ 的定义不同，不应混为同一个相对残差。

精度怎么估计

双精度 `eps(Float64)` 约为 2.22×10^{-16}。稳定算法在数据足够准确且其他误差受控时，常用 $\kappa\epsilon_{\mathrm{mach}}$ 判断最坏情况下的相对误差尺度。若 $\kappa \approx 10^q$，可能损失约 q 位十进制有效数字；不是必然损失，也不是精确位数保证。原始测量只有 6 位时，不能按 16 位起算。

若 $\kappa\epsilon_{\mathrm{mach}} \gtrsim 1$，当前精度下不应指望有可靠相对精度。更稳的算法不能恢复输入里已丢失的信息；可考虑改尺度、改模型或提高输入和计算精度。

教材 Demo 2.8.3 实际使用 $A_{ij} = 1/(i+j)$，索引从 1 开始；这与常见 Hilbert 矩阵 $1/(i+j-1)$ 相差一个偏移。做本版本题目应沿用教材定义，不要混表。病态程度超过浮点可分辨范围后，计算出的条件数也可能不再可靠。

补充性质：对同一种诱导范数，$\kappa(AB) \le \kappa(A)\kappa(B)$；非零标量 α 不改变 $\kappa(\alpha A)$。对角矩阵若所有对角元素非零，$\kappa_p(D) = \max_i |D_{ii}| / \min_i |D_{ii}|$（$p = 1, 2, \infty$）；若有零则奇异，直接按约定取无穷大。

2.9. Exploiting matrix structure | 利用矩阵结构

来源：2.9。对应 Banded matrices、Symmetric matrices、Symmetric positive definite matrices。

严格对角占优与带状矩阵

本节所说的对角占优使用严格不等式：

$$|A_{ii}| > \sum_{j \ne i} |A_{ij}| \quad \text{对每一行成立.}$$

严格行对角占优保证可逆，通常可不用换行来稳定消元。不能将它擅自放宽为 $\ge$ 后还保留结论，也不能据此断言条件数很小。

上带宽 b_u 表示 $j - i > b_u$ 的位置均为零；下带宽 b_ℓ 表示 $i - j > b_\ell$ 的位置均为零。总带宽是 $b_u + b_\ell + 1$。三对角矩阵有 $b_u = b_\ell = 1$。

不换行 LU 若可顺利进行，L, U 分别保留原来的下、上带宽。只在非零带内更新，可使分解成本降为 $O(n b_u b_\ell)$（此处按两侧带宽均为正的常用情形表述；三角退化情形直接用三角求解）。固定小带宽时，成本随 n 近似线性。若换行，带外可能产生填充，不能直接沿用原带宽不变的结论。

存成很多零的普通矩阵，不等于实现已利用结构。 使用专门类型或算法才能得到预期的存储与算术节省。Julia 常用 `Tridiagonal`、`Diagonal`、`LowerTriangular`、`UpperTriangular`；一般稀疏矩阵可用 `SparseArrays` 的 `sparse`、`spdiagm`。

对称矩阵：LDL^T

实对称矩阵适合保持对称的分解

$$A = LDL^T, \qquad LDL^T = \sum_k d_k \ell_k \ell_k^T.$$

L 为单位下三角，D 为对角阵。只处理一个三角部分，成功时约需 $n^3/3$ flop。**一般对称矩阵的无主元对角 D 分解仍可能失败或不稳定**，不能仅凭对称就省略选主元；更通用的带主元方法可能使用块对角 D，超出本章主线。

SPD 与 Cholesky

实矩阵为对称正定（SPD），必须同时满足 $A^T = A$ 与

$$x^T A x > 0 \quad \text{对所有 } x \ne 0.$$

$x^T A x = \sum_{i,j} A_{ij} x_i x_j$ 称为二次型。对称矩阵正定等价于所有特征值为正，但本章不要求先会特征值算法。取 $x = e_i$ 可知 SPD 的对角元全为正；反过来不成立，元素全正也不保证 SPD。

SPD 的 LDL^T 有 $D_{ii} > 0$，故可令

$$R = D^{1/2} L^T, \qquad A = R^T R.$$

这就是 **Cholesky 分解**，R 上三角且对角元为正。它不需要换行，稳定，约需 $n^3/3$ flop。解方程时先解 $R^T z = b$，再解 $Rx = z$。

补充算例：

$$\begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 1 & \sqrt{2} \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 0 & \sqrt{2} \end{bmatrix}.$$

对任意实矩阵 B，$B^T B$ 总是半正定；B **满列秩**时才正定。特别地，可逆方阵 B 保证这一点，因为 $x^T B^T B x = \|Bx\|_2^2 > 0$。

调用库时先确认对称性，再运行 Cholesky。`Symmetric(A)` 是对结构的声明，不是对两个三角部分一致性的检验；错误声明可能使库只采用其中一半数据。

已知结构	首选思路	不能省略的检查
一般可逆稠密方阵	带部分选主元的 LU	残差与条件数
已有三角矩阵	前代或回代	对角非零
带状 / 三对角	专用带状或三对角求解器	选主元与填充的影响
对称但未证正定	支持对称不定问题的分解	不直接假设可用 Cholesky
已证 SPD	Cholesky	对称性、数值正定性

2.10. Next steps | 后续阅读

来源：2.10。本节没有新算法、定理或习题；它列出线性代数、数值线性代数和稳定性分析的延伸资料。

需要补基础时回到教材附录 *Review of linear algebra*；进一步学习可依原文查阅 Strang、Lay、Leon 的线性代数教材，Trefethen–Bau 的 *Numerical Linear Algebra*，Golub–Van Loan 的 *Matrix Computations*，Higham 的 *Accuracy and Stability of Numerical Algorithms*。初次三小时学习不包含这些阅读。

一次完整应用：从求解到诊断

以下为编者补充的最小 Julia 脚本，只使用标准库。独立可运行版本为 `practice.jl`。本次环境未安装 Julia；公式和数值结果另以本地 Python 核算，未宣称 Julia 已实机运行。

```
using LinearAlgebra
A = [2.0 1.0; 4.0 3.0]
b = [3.0, 7.0]
F = lu(A)                    # 一次分解
x = F \ b                    # [1,1]
r = b - A*x
rho = norm(r) / norm(b)
eta = norm(r) / (opnorm(A)*norm(x) + norm(b))
kappa = cond(A)
@show x rho eta kappa kappa*rho
# 更换右端项时复用 F:
B = [3.0 1.0; 7.0 0.0]
```

```
X = F \ B
@show norm(B - A*X)
```

实际判断顺序：先检查模型、单位和尺寸，再选适合结构的求解器，最后看相对残差与条件数。上界很大只说明这个检验不足以保证准确，不等于已经证明误差很大。

闭卷自检（先做，再翻答案）

1. 对 $t=-1,0,1$ 和 $y=2,1,2$，写出 $Vc=y$，求系数并预测 $t=0.5$ 的值。
2. 对上文 2.3 的 3×3 下三角例子写出前代过程。再解释 $A=LU$ 时为什么先解 $Lz=b$。
3. 某次带主元分解满足 $A[[3,1,2],:]=LU$。求解时 b 的顺序是什么？若换成一个新 b，是否必须重新分解？
4. 对 $v=(-2,1,2)^T$，求三种向量范数；对 $A=\begin{bmatrix}1 & -2\\ 3 & 4\end{bmatrix}$，求矩阵 1 范数、$\infty$ 范数和 Frobenius 范数。
5. 相对残差是 10^{-12}，$\kappa(A)=10^{10}$。可由本章定理保证什么？可以宣称解有 12 位有效数字吗？
6. 同一个稠密 $n\times n$ 矩阵要解 100 个右端项，写出复用分解的成本。若 n 加倍，分解主项如何变化？
7. $A=\begin{bmatrix}1 & 2\\ 2 & 1\end{bmatrix}$ 对角元均正，是否 SPD？$B=\begin{bmatrix}2 & -1\\ -1 & 2\end{bmatrix}$ 应选什么分解？

自检答案与修正理由

1. $V=\begin{bmatrix}1 & -1 & 1\\ 1 & 0 & 0\\ 1 & 1 & 1\end{bmatrix}$，$c=(1,0,1)^T$，$p(0.5)=1.25$。未知量是系数，列指数从 0 开始。
2. $x_1=2/2=1$，$x_2=5-3x_1=2$，$x_3=(15+x_1-2x_2)/4=3$。由 $L(Ux)=b$，令 $z=Ux$ 才得到正确顺序。
3. 使用 $(b_3,b_1,b_2)^T$；同一 A 无需重新分解，只做两次三角求解。
4. 向量范数为 $5,3,2$；矩阵范数依次为 $6,7,\sqrt{30}$。检查是否把“行和 / 列和”或 `norm` / `opnorm` 混淆。
5. 理论上界为 10^{-2}，只能由该界保证相对误差不超过约 1%。不能宣称 12 位准确；实际误差也可能远小于上界。
6. 约 $\frac{2}{3}n^3+200n^2$ flop；n 加倍使分解主项约乘 8。
7. 第一个矩阵不是 SPD，取 $x=(1,-1)^T$ 得 $x^TAx=-2$。第二个是 SPD，因二次型为 $(x_1-x_2)^2+x_1^2+x_2^2>0$，宜用 Cholesky。

如果不会 1–3，回到建模与分解；如果不会 4–5，回到误差判断；如果不会 6–7，回到成本与结构。能阅读公式但不能完成这些检查，还不能算“能够运用本章”。

覆盖核对与来源

2.1–2.10 均已覆盖，相关习题延伸结论标为补充。各节开头提供原文链接，保留经核对的原式编号；完整原题、数据和分问另收于习题册。

原作作者为 Tobin A. Driscoll 与 Richard J. Braun，Julia 版原作版权为 SIAM 2022。本讲义新增中文讲解、图示与例子按 CC BY-SA 4.0 提供，不改变原教材正文的权利声明。